Centinela del Café · Fase 1: línea base con MLP para detectar hojas de café afectadas

Briyith Lisdey Herrera Cruz · Juan Pablo Becerra Tirano · Johnatan Vélez Martínez — Deep Learning, Maestría en Ciencia de Datos, Universidad Santo Tomás · 2026-11-04

1. Problema y cliente

Las **organizaciones de monitoreo fitosanitario** envían técnicos de sanidad vegetal a revisar lotes de café. No pueden inspeccionar cada hoja, y una hoja con **roya** (*Hemileia vastatrix*) o **ácaro rojo** que pasa inadvertida sigue esporulando o reproduciéndose y contagia el lote. El objetivo es binario: **¿la hoja está afectada (ácaro o roya de cualquier nivel = 1) o sana (= 0)?** Se resuelve a partir de una foto de celular. El error más costoso es el **falso negativo** (FN). Un falso positivo (FP) cuesta una verificación en campo; se asume FN:FP = 5:1, dentro del rango de 3 a 8 veces que cuesta dejar pasar un defecto en un control de calidad. La meta operativa es un *recall* de la clase afectada ≥ 0,90. Esta Fase 1 construye la línea base con un perceptrón multicapa (MLP). La Fase 2 incorporará la serie climática.

2. Datos

Fuente. RoCoLe v2 (Parraga-Alava et al., 2019a, 2019b; CC BY 4.0), descargado de Mendeley Data. Son 1560 fotos de 390 plantas de café robusta, en 12 cultivos, tomadas en CIIDEA, Manabí, Ecuador. Cada planta tiene 4 fotos: 2 del haz y 2 del envés. Por cómo coinciden sus etiquetas, se infiere que corresponden a 2 hojas fotografiadas por ambas caras, unas 780 hojas en total, aunque la fuente no lo documenta. Hay 791 hojas sanas, 167 con ácaro rojo y 602 con roya: el balance es 769 afectadas frente a 791 sanas. Este dataset reemplaza al de cacao de la propuesta v1. Sus autores confirmaron que las fotos se tomaron en Tocache, Huallaga y Rioja, pero ninguna imagen registra dónde, lo que impedía alinear cada foto con el clima. En RoCoLe, el sitio es único y georreferenciado, y la fecha de cada foto está en el EXIF.

Huella de crudeza. El CSV de anotaciones llega con 1560 × 18 celdas y 23,5 % de faltantes. Las imágenes vienen de 4 celulares, en 3 resoluciones y 5 fechas. Hay **67 grupos de imágenes idénticas byte a byte** (134 imágenes) entre plantas distintas. En 27 de ellos las copias tienen clase multiclase distinta, es decir, hay ruido de etiqueta en la fuente. Por decisión del equipo **no se eliminan**: se conservan con su etiqueta original y se agrupan para que nunca queden repartidos entre entrenamiento y prueba. El dato del anotador (*Created By*) se eliminó al cargar los datos.

De imagen a tabla. La modalidad que se aplana en esta fase es la imagen. Sobre los píxeles del polígono anotado de la hoja, redimensionada a 256 px, se calculan 28 rasgos: color RGB, HSV y CIELAB; proporciones de píxeles anaranjados, amarillos y oscuros; los índices ExG, VARI y R/G; textura GLCM, y la fracción que ocupa la hoja. Al modelo entran 27, porque *pct_verde* es igual a 1 − *pct_lesion*.

Hallazgos del EDA → decisiones. No hay NaN (0). Los ceros de *pct_naranja* se concentran en hojas sanas: son biológicos. Los atípicos por IQR son la propia señal de la enfermedad: en *pct_amarillo*, el 54,3 % de las hojas con roya 3–4 son atípicas, frente al 1,6 % de las sanas. Por eso **no se eliminan atípicos**. Hay 14 pares de rasgos con |ρ| > 0,9; se conservan, porque elegir variables con todo el conjunto filtraría información. La clase casi no depende del dispositivo (V de Cramér = 0,028) ni de la fecha (0,024), pero dispositivo y fecha están confundidos entre sí.

Partición. La partición es estratificada y **agrupada**: las 390 plantas, unidas por sus duplicados (SHA-256 y pHash), forman 342 grupos. Quedan 1092 imágenes de entrenamiento, 232 de validación y 236 de prueba (70,0 % / 14,9 % / 15,1 %), con semilla 42. El *StandardScaler* se ajusta solo con entrenamiento.

Acoplamiento con el clima (para la Fase 2). La clave es (CIIDEA, fecha EXIF), con una ventana de 60 días de NASA POWER. Las 5 ventanas resultan casi idénticas: temperatura de 25,66 a 25,80 °C y humedad relativa de 85,8 a 86,2 %. El clima aportará contexto de riesgo, no señal por hoja.

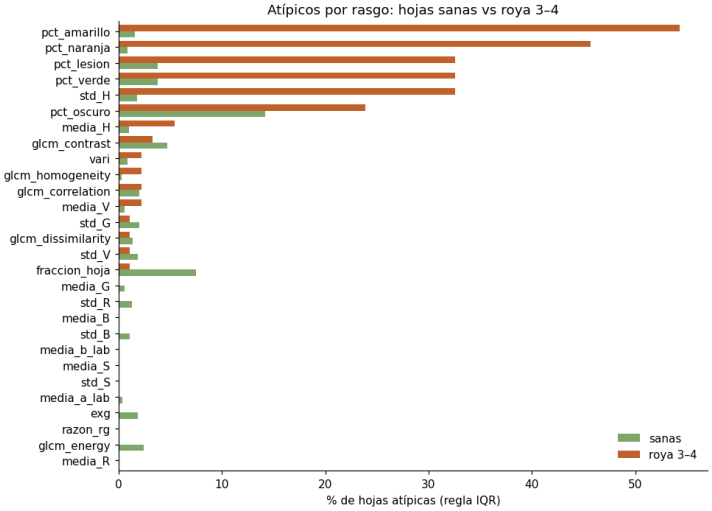


Figura 1. Porcentaje de hojas atípicas (regla IQR) por rasgo: sanas frente a roya 3–4. Los atípicos de los rasgos de lesión corresponden a enfermedad severa y se conservan.

3. Modelo y entrenamiento

Arquitectura. MLP en PyTorch con dos capas ocultas (Linear → ReLU → Dropout) y una salida Linear(k, 1) que devuelve un **logit**. Se entrena con *BCEWithLogitsLoss*, la etiqueta tiene forma (N, 1) en float y la sigmoide se aplica solo al evaluar, para evitar el doble sigmoide. ReLU es necesaria porque las señales interactúan: un tono anaranjado solo indica roya si va acompañado de textura punteada y pérdida de verdor, y ese tipo de interacción no lo representa una frontera lineal. Sin activación no lineal, varias capas lineales se reducen a una sola; con ReLU, el MLP aproxima esas interacciones por tramos (Teorema de Aproximación Universal; Goodfellow et al., 2016). El bucle es explícito (forward → pérdida → zero_grad → backward → step), con Adam, lr = 10^{-2} y lote completo; se guarda un *checkpoint* cada 10 épocas.

Experimentos. La corrida R1 (256 → 128, sin Dropout, 1.500 épocas) se **sobreajusta**: la pérdida de validación toca su mínimo (0,369) en la época 30 y luego sube, y la brecha validación − entrenamiento pasa de 0,135 a 1,99. La parada temprana usa paciencia de 25 épocas, porque con lote completo una época es un solo paso de gradiente. Con esa paciencia y Dropout 0,3, la pérdida mínima de validación baja a 0,361 (R2, 16 → 8) y a 0,324 (R3a, 8 → 4). La comparación de capacidad muestra que la red grande R3b (64 → 32) casi no mejora la pérdida (0,327) y multiplica la brecha (0,111 frente a 0,002). Por eso se elige **R3a** (8 → 4, Dropout 0,3, parada temprana), con el estado del mínimo de validación restaurado.

Corrida	Ocultas	Regularización	Época mín.	Pérdida val. mín.	Brecha en mín.	AUC val.
R0	(16, 8)	—	42	0,418	0,028	0,897
R1	(256, 128)	—	30	0,369	0,135	0,911
R1-ES	(256, 128)	— + PT	30	0,369	0,135	0,941
R2	(16, 8)	Dropout 0,3 + PT	128	0,361	0,056	0,942
R3a	(8, 4)	Dropout 0,3 + PT	165	0,324	0,002	0,943
R3b	(64, 32)	Dropout 0,3 + PT	97	0,327	0,111	0,948
R4	(16, 8)	Dropout 0,3 + L2 + PT	123	0,359	0,046	0,943

Tabla 1. Corridas comparables (misma partición, semilla y lr). PT = parada temprana. Brecha = pérdida de validación − pérdida de entrenamiento en la época del mínimo.

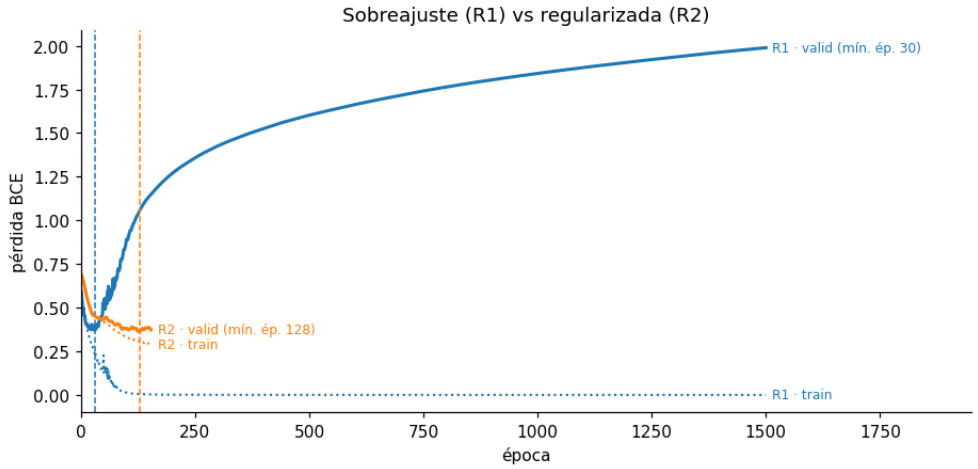


Figura 2. Pérdida por época en entrenamiento (punteada) y validación (continua) de R1 (sobreajuste) y R2 (regularizada). La línea discontinua vertical marca el mínimo de validación.

4. Resultados y errores

El umbral se fijó en **validación** como el de menor costo 5·FN + FP con *recall* ≥ 0,90: **0,22**. Con él, el conjunto de prueba se evaluó **una sola vez** (n = 236).

Modelo	Recall afectada	Precisión afectada	F1 afectada	Recall sana	AUC	FN	FP	Costo
MLP R3a	0,975	0,748	0,847	0,667	0,936	3	39	54
Escalar crudo pct_lesion	0,992	0,578	0,731	0,265	0,789	1	86	91
Clase mayoritaria (sana)	0,000	0,000	0,000	1,000	0,500	119	0	595

Tabla 2. Desempeño en prueba frente a las dos líneas base comprometidas.

El MLP detecta 116 de 119 hojas afectadas (*recall* 0,975) con AUC = 0,936. Frente al escalar crudo, reduce el costo de 91 a 54 y los falsos positivos de 86 a 39. La clase mayoritaria no detecta ninguna hoja (costo 595). **Análisis de errores:** los 3 FN son lesiones incipientes (detección de 0,964 en roya 1 y 0,964 en ácaro rojo, frente a ≥ 1,00 en roya 2–4). Es el caso que más le importa a una alerta temprana. Los FP de mayor probabilidad que se revisaron en la galería del notebook son hojas sanas con brillos o tonos amarillentos. Es coherente con que el modelo dependa sobre todo del color de la lesión (importancia por permutación: *pct_naranja* 0,143, *pct_amarillo* 0,102). **Por subgrupo:** el *recall* es estable entre celulares, pero la tasa de falsa alarma en hojas sanas va de 0,10 a 0,54 según la cámara.

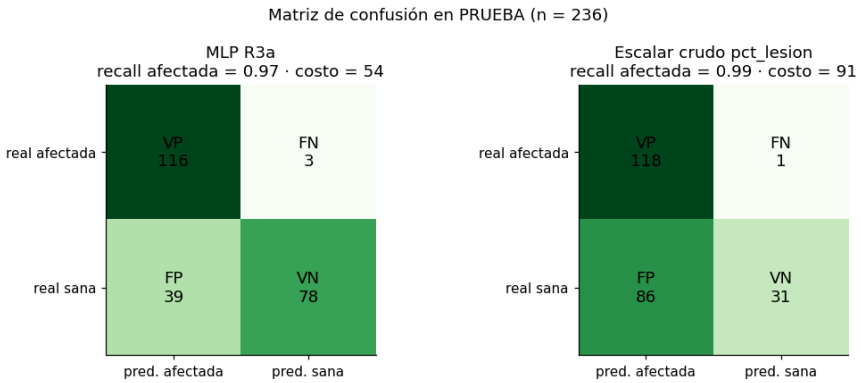


Figura 3. Matriz de confusión en prueba del MLP y del escalar crudo, cada uno con el umbral elegido en validación.

5. Decisión recomendada y riesgos éticos

Decisión. Adoptar el MLP R3a con umbral 0,22 como **filtro de priorización de inspección**, no como diagnóstico. Toda alerta la confirma el técnico en campo antes de cualquier aplicación. Sin el modelo, el técnico tendría que revisar las 236 hojas; con él revisa 155 y deja escapar 3.

Marco Ético para la IA en Colombia (Guío Español et al., 2021). **Responsabilidad:** el umbral se fijó por el costo del error para el cliente, no en 0,5, y la decisión final queda en manos humanas. **Transparencia:** el sistema declara su dominio de validez (robusta, un sitio, 5 días de 2019, 4 celulares Samsung), informa que "sin alerta" no equivale a "sana" y reporta la falsa alarma por dispositivo. **Equidad y beneficio social:** no debe extrapolarse a café arábica ni a fincas colombianas sin un piloto local; hacerlo trasladaría el riesgo de FN a productores que el modelo no vio.

Riesgos y mitigaciones. (1) Ruido de etiqueta en duplicados: se reporta y se agrupa. (2) La máscara de la hoja proviene de la anotación humana: en uso real hará falta segmentación automática (Fase 2). (3) El clima casi constante limita la rama temporal. (4) **Auditoría a la IA, caso real:** el asistente generó el bucle con una paciencia de 10 épocas. Con lote completo eso equivale a solo 10 pasos de gradiente, y R2 se detenía en una meseta. Reproducido con la misma semilla, la paciencia 10 deja una AUC de validación de 0,893 y un costo de 79; la paciencia corregida (25) da 0,942 y 53. **Modificada:** la sugerencia de partir por hoja se cambió a partir por planta. Partiendo por hoja, un 99,1 % de las fotos de prueba tendría una hermana en entrenamiento, y 20 serían copias exactas. **Rechazada:** eliminar duplicados. Con datos tabulares la comparación de filas no reconoce el contexto ni las vecindades de la imagen, y se corre el riesgo de borrar registros que no son duplicados; además, 27 grupos de copias exactas tienen clases distintas. Por eso se conservan y solo se agrupan. La partición, la semilla y las líneas base se conservan para la Fase 2 (CNN + LSTM/GRU con fusión).

Referencias

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press. https://www.deeplearningbook.org/

Guío Español, A., Tamayo Uribe, E., Gómez Ayerbe, P., & Mujica, M. P. (2021). *Marco ético para la inteligencia artificial en Colombia*. Consejería Presidencial para Asuntos Económicos y Transformación Digital.

NASA Langley Research Center. (2026). *Prediction of Worldwide Energy Resources (POWER) Project: Daily agroclimatology data* [Data set]. https://power.larc.nasa.gov/

Parraga-Alava, J., Cusme, K., Loor, A., & Santander, E. (2019a). *RoCoLe: A robusta coffee leaf images dataset* (Version 2) [Data set]. Mendeley Data. https://doi.org/10.17632/c5yvn32dzg.2

Parraga-Alava, J., Cusme, K., Loor, A., & Santander, E. (2019b). RoCoLe: A robusta coffee leaf images dataset for evaluation of machine learning based methods in plant diseases recognition. *Data in Brief, 25*, 104414. https://doi.org/10.1016/j.dib.2019.104414

Rengifo-Lozano, D., & Sánchez-Flores, J. (2026). *Image dataset of healthy and monilia-infected cocoa pods for disease classification* (Version 1) [Data set]. Mendeley Data. https://doi.org/10.17632/ykbtpsyfv9.1