Centinela del Café: alerta temprana de hojas de café afectadas

Informe técnico-ético · Proyecto Centinela, Fase 1 · Briyith Lisdey Herrera Cruz, Juan Pablo Becerra Tirano y Johnatan Vélez Martínez · Deep Learning, Maestría en Ciencia de Datos, Universidad Santo Tomás · 2026-11-05

En breve

- Construimos un modelo que mira la foto de una hoja de café y avisa si puede estar enferma (roya o ácaro rojo).
- En 236 hojas que el modelo nunca había visto, detectó **116 de 119** hojas enfermas (97,5 %), a cambio de 39 falsas alarmas entre 117 hojas sanas.
- Comparado con mirar un solo indicador de color, reduce el costo de los errores en un **41 %**.
- Recomendación: usarlo para decidir qué hojas revisar primero, nunca como diagnóstico final.

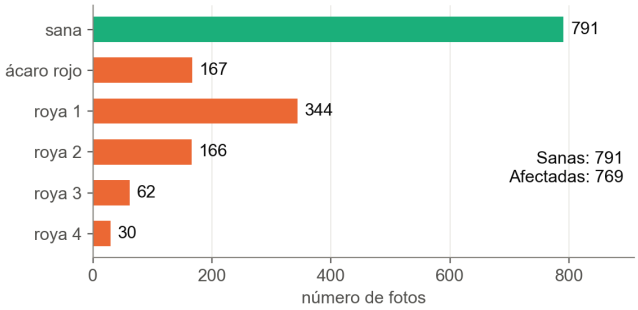
1. El problema y para quién

Las **organizaciones de monitoreo fitosanitario** envían técnicos de sanidad a revisar cultivos de café, pero no pueden inspeccionar cada hoja. La **roya** (un hongo que deja manchas anaranjadas) y el **ácaro rojo** se propagan si no se detectan a tiempo. La pregunta del proyecto es simple: **a partir de una foto, ¿la hoja está afectada o sana?**

Hay dos errores posibles. Un **falso negativo** es una hoja enferma que el sistema deja pasar: sigue contagiando el cultivo. Un **falso positivo** es una falsa alarma: el técnico revisa una hoja que estaba sana. Con el equipo acordamos que **dejar pasar una hoja enferma cuesta 5 veces más** que una falsa alarma, en línea con lo que cuesta dejar pasar un defecto en un control de calidad (de 3 a 8 veces). La meta fue detectar al menos el 90 % de las hojas enfermas.

2. Los datos

Usamos **RoCoLe**, un conjunto público de fotos de hojas de café robusta tomadas en una finca experimental de Manabí, Ecuador (Parraga-Alava et al., 2019a, 2019b). Son **1.560 fotos de 390 plantas** en 12 lotes: 4 fotos por planta, que corresponden a unas 780 hojas fotografiadas por ambas caras. Cada foto trae la clase asignada por un experto y la fecha en que se tomó. Esa fecha permitirá en la Fase 2 unir cada hoja con el clima de los 60 días anteriores (NASA Langley Research Center, 2026). Este conjunto reemplazó a uno de mazorcas de cacao (Rengifo-Lozano y Sánchez-Flores, 2026): sus autores nos confirmaron que no registraron dónde se tomó cada foto, y sin ese dato no se puede cruzar la foto con el clima.



Calidad de los datos. Encontramos 67 grupos de fotos repetidas idénticas, y en 27 de ellos las copias tienen etiquetas distintas. Decidimos **no borrarlas**: borrar obligaría a escoger una etiqueta sin criterio. Se mantienen juntas, para que una copia no aparezca a la vez en las fotos de práctica y en las de prueba.

Privacidad. Las fotos solo muestran hojas, no tienen ubicación GPS, y se eliminó el único dato personal: el nombre de quien etiquetó cada foto.

Figura 1. Fotos por clase. Las clases de roya van de 1 (leve) a 4 (severa). Las sanas y las afectadas están casi en igual proporción.

3. Cómo funciona el modelo

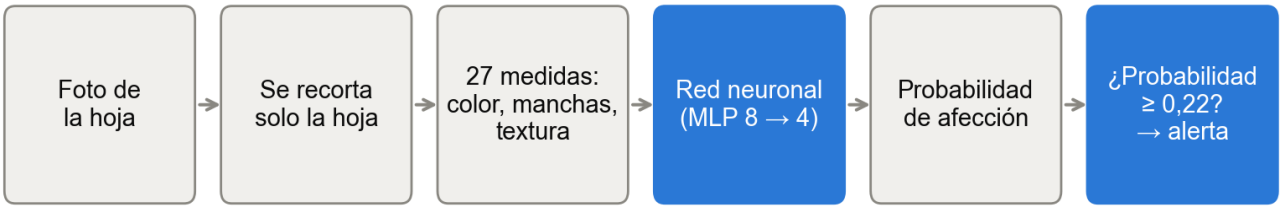
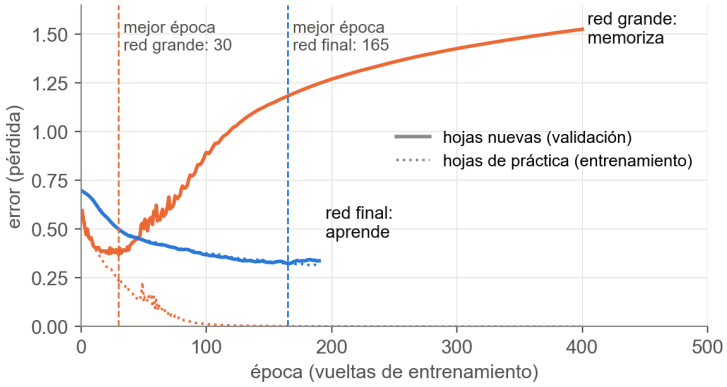


Figura 2. Recorrido de una foto por el sistema.

- **De foto a números.** Se recorta solo la hoja y se resume en 27 medidas con sentido agronómico: qué tan verde es, qué parte tiene manchas anaranjadas, amarillas u oscuras, y qué tan lisa o punteada es su textura.
- **La red neuronal (MLP).** Recibe las 27 medidas y las combina en dos capas de 8 y 4 "neuronas". Usa la función de activación **ReLU**, que le permite aprender combinaciones: una mancha anaranjada indica roya solo si va con textura punteada y pérdida de verde (Goodfellow et al., 2016).
- **Cómo aprende.** Compara su respuesta con la etiqueta del experto mediante la **entropía cruzada binaria**, una medida de error que castiga más los errores cometidos con seguridad. Corrige sus pesos con el método **Adam** (Kingma y Ba, 2015).

- **Práctica y examen separados por planta.** El modelo practica con el 70 % de las plantas, se ajusta con el 15 % y se examina con el otro 15 %. Separar por planta, y no por foto, evita que una hoja "vista" en la práctica reaparezca en el examen: si se separara por foto, el 99 % de las fotos del examen tendría una hermana en la práctica.



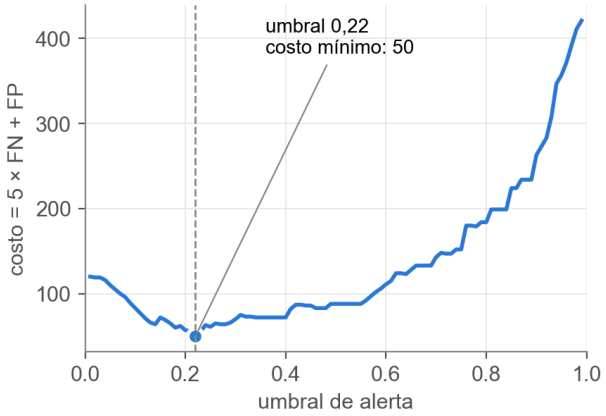
Aprender sin memorizar. Una red grande (256 y 128 neuronas) mejora hasta la época 30 y luego empieza a **memorizar**: su error con hojas nuevas se dispara. La red final es pequeña, apaga neuronas al azar durante la práctica (*dropout*) y se detiene sola cuando deja de mejorar (**parada temprana**). Su mejor punto fue la época 165.

Comparamos tres tamaños con hojas nuevas. El error fue de 0,324 para 8 → 4 neuronas, 0,361 para 16 → 8 y 0,327 para 64 → 32. La red más pequeña generaliza igual o mejor.

Figura 3. Error por época con hojas nuevas (línea continua) y con hojas de práctica (punteada). Cuando las dos líneas se separan, el modelo está memorizando.

4. Resultados y errores

El modelo no responde sí o no: da una **probabilidad** de que la hoja esté afectada. El **umbral** es el punto de corte para dar la alerta. No usamos 0,5: probamos todos los cortes con hojas de ajuste y elegimos el de menor costo (Figura 4). Con **0,22** basta un 22 % de probabilidad para alertar, porque dejar pasar una hoja enferma es lo más caro. Un corte de 0,10 dejaría pasar 0 hojas enfermas pero daría 83 falsas alarmas; uno de 0,50 daría 13 falsas alarmas pero dejaría pasar 15 hojas enfermas.



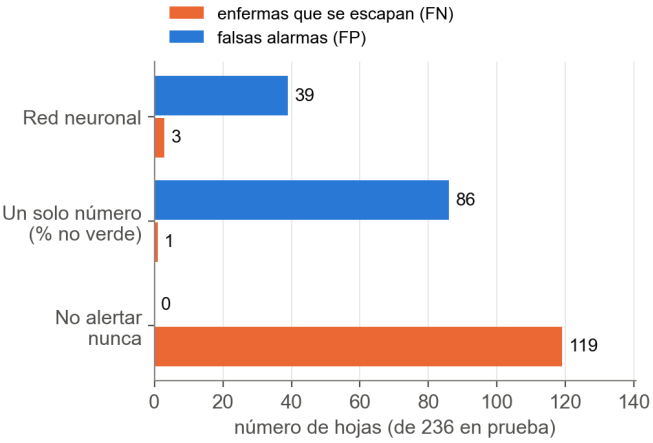


Figura 4 (izq.). Costo de los errores según el umbral, en hojas de ajuste. Figura 5 (der.). Errores en el examen final (236 hojas nuevas, evaluadas una sola vez) frente a dos alternativas simples.

	Red neuronal	Un solo número (% no verde)	No alertar nunca
Hojas enfermas detectadas	116 de 119 (97,5 %)	118 de 119 (99,2 %)	0 de 119
De cada 100 alertas, cuántas son reales	75	58	—
Costo total (5 × FN + FP)	**54**	91	595

¿Qué se escapa? Sobre todo las lesiones **incipientes**: roya leve (nivel 1) y ácaro rojo, con 96 % de detección cada una. Las de roya 2 a 4 se detectaron todas. **¿Dónde hay más falsas alarmas?** Depende del celular que tomó la foto: entre 10 % y 54 % de las hojas sanas, según el modelo de cámara. El modelo se guía sobre todo por el color de las manchas, y los brillos o tonos amarillentos de algunas fotos lo confunden.

5. Decisión recomendada y riesgos éticos

Recomendación. Usar el modelo con umbral 0,22 como **filtro para priorizar la inspección**. De 236 hojas, el técnico revisaría 155 y solo se escaparían 3. Toda alerta se confirma en campo antes de aplicar cualquier producto.

Principios del Marco Ético para la Inteligencia Artificial en Colombia (Guío Español et al., 2021):

- **Responsabilidad:** el umbral se fijó según el daño que causa cada error al cliente, y la decisión final la toma una persona.
- **Transparencia:** el sistema declara sus límites. Se entrenó con café robusta de una sola finca, con fotos de 5 días de 2019 y 4 celulares. "Sin alerta" no significa "sana", y las falsas alarmas se vigilan por celular.

- **Equidad y beneficio social:** no debe usarse en café arábica ni en fincas colombianas sin una prueba piloto local, para no trasladar el riesgo de errores a productores que el modelo nunca vio.

Uso responsable de la IA. Revisamos las sugerencias del asistente de IA usado en el desarrollo. Rechazamos una (borrar fotos duplicadas) y corregimos dos: separar los datos por planta y no por foto, y dar más tiempo a la parada temprana. Esta última corrección mejoró la capacidad del modelo para distinguir hojas (AUC) de 0,893 a 0,942. **Próximo paso (Fase 2):** una red que lea la foto directamente y la combine con el clima de los 60 días previos.

Glosario

- **Falso negativo (FN):** hoja enferma que el sistema deja pasar sin alerta.
- **Falso positivo (FP):** falsa alarma: hoja sana marcada como afectada.
- **Detección (*recall*):** de todas las hojas enfermas, qué porcentaje detecta el sistema.
- **Umbral:** probabilidad mínima a partir de la cual el sistema da la alerta.
- **AUC:** capacidad del modelo para ordenar las hojas enfermas por encima de las sanas (0,5 = azar; 1 = perfecto).
- **Época:** una vuelta completa del modelo sobre las fotos de práctica.
- **Sobreajuste:** cuando el modelo memoriza las fotos de práctica y empeora con fotos nuevas.
- **Validación y prueba:** fotos apartadas para ajustar el modelo (validación) y para el examen final (prueba), que se usa una sola vez.

Referencias

Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press. https://www.deeplearningbook.org/

Guío Español, A., Tamayo Uribe, E., Gómez Ayerbe, P., & Mujica, M. P. (2021). *Marco ético para la inteligencia artificial en Colombia*. Consejería Presidencial para Asuntos Económicos y Transformación Digital.

Kingma, D. P., & Ba, J. (2015). Adam: A method for stochastic optimization. En *3rd International Conference on Learning Representations (ICLR)*. https://doi.org/10.48550/arXiv.1412.6980

NASA Langley Research Center. (2026). *Prediction of Worldwide Energy Resources (POWER) Project: Daily agroclimatology data* [Data set]. https://power.larc.nasa.gov/

Parraga-Alava, J., Cusme, K., Loor, A., & Santander, E. (2019a). *RoCoLe: A robusta coffee leaf images dataset* (Version 2) [Data set]. Mendeley Data. https://doi.org/10.17632/c5yvn32dzg.2

Parraga-Alava, J., Cusme, K., Loor, A., & Santander, E. (2019b). RoCoLe: A robusta coffee leaf images dataset for evaluation of machine learning based methods in plant diseases recognition. *Data in Brief, 25*, 104414. https://doi.org/10.1016/j.dib.2019.104414

Rengifo-Lozano, D., & Sánchez-Flores, J. (2026). *Image dataset of healthy and monilia-infected cocoa pods for disease classification* (Version 1) [Data set]. Mendeley Data. https://doi.org/10.17632/ykbtpsyfv9.1